

11 Listopad 2024

Katarzyna Jaczewska

11 Listopad 2024

Spis treści

1	Wstęp	3
2	Rozdział 1 - Analiza kursów zamknięcia i logarytmicznych zwrotów	3
2.1	Część 1 – Grupa Żywiec ()	3
2.1.1	Wykresy	3
2.1.2	Estymacja parametrów	4
2.1.3	Estymacja kwantyli	4
2.1.4	Estymator dystrybuanty	5
2.1.5	Część 2 – Estymacja parametrów rozkładu normalnego i t-Studenta oraz ocena dopasowania	6
2.1.6	Estymacja parametrów za pomocą MLE	6
2.1.7	Wykresy diagnostyczne	6
2.1.8	Testy dobroci dopasowania oraz kryteria informacyjne	7
2.1.9	Test hipotezy o równości rozkładów	9
		10
2.2		10
		11
2.2.2	Estymacja parametrów	12
2.2.3	Estymacja kwantyli	13
2.2.4	Histogram z wyróżnionymi kwantylami	13
2.2.5	Interpretacja kwantyli	13
2.2.6	Estymator dystrybuanty	14
2.2.7	Część 2 – Estymacja parametrów rozkładu normalnego i t-Studenta oraz ocena dopasowania	15
2.2.8	Estymacja parametrów za pomocą MLE	15
2.2.9	Wykresy diagnostyczne	15
2.2.10	Opis wykresów diagnostycznych	15
2.2.11	Wnioski	16
2.2.12	Testy dobroci dopasowania oraz kryteria informacyjne	16
2.2.13	Test metodą Monte Carlo hipotezy o równości rozkładów	17
3	Rozdział 2 - Analiza łącznego rozkładu log-zwrotów	18
3.0.1	Estymatory parametrów	18
3.0.2	Wyniki obliczeń	18
3.0.3	Wzór gęstości rozkładu $\hat{f}$ normalnego o wyestymowanych parametrach $N(\hat{\mu}, \hat{\Sigma})$	20
3.0.4	Wzory gęstości brzegowych	21
3.0.5	Wyniki graficzne	22
3.0.6	Próba liczebności danych z rozkładu	24

3.1	Porównanie wykresów rozrzutu i ocena zgodności z rozkładem normalnym	24
3.1.1	Porównanie wykresów rozrzutu	24
3.1.2	Ocena wstępna zgodności	25
3.1.3	Wnioski	25
4	Rozdział 3 - Regresja liniowa dla log-zwrotów	25
4.1	Przedziały ufności dla wartości oczekiwanej log-zwrotów	25
4.1.1	Wnioski	26
4.2	Teoria regresji liniowej	26
4.2.1	Dopasowanie modelu	26
4.2.2	Analiza reszt	27
4.2.3	Predykcja	27
4.2.4	Wizualizacja dopasowania	28
4.3	Analiza Modelu Uproszczonego	29
4.3.1	Dopasowanie modelu uproszczonego	29
4.3.2	Predykcja w modelu uproszczonym	29
4.3.3	Przedziały ufności dla predykcji w modelu uproszczonym	29
4.3.4	Porównanie przedziałów ufności	29
4.3.5	Wnioski z analizy modelu uproszczonego	30
4.4	Podsumowanie	30
4.4.1	Wnioski	30
5	Podsumowanie	30

2.1 Część 1 – Grupa Żywiec

płynności i zmienności notowań podkreśla znaczenie oceny ryzyka inwestycyjnego oraz analizy rozkładu zwrotów. Logarytmiczne zwroty akcji, dzięki swoim własnościom statystycznym, są powszechnie stosowane w analizach portfelowych, wycenie opcji i badaniach rynku.

Celem pracy jest analiza statystyczna cen i logarytmicznych zwrotów wybranych spółek giełdowych. Obejmuje ona estymację parametrów (wartości oczekiwanej, wariancji, kwantyli), zweryfikowanie dopasowania rozkładów teoretycznych (normalnego i t-Studenta) do danych empirycznych, analizę własności łącznych rozkładów log-zwrotów spółek, obliczenie macierzy kowariancji i współczynnika korelacji oraz modele regresji liniowej dla logarytmicznych zwrotów z uwzględnieniem oceny dopasowania modelu, analizy reszt oraz przedziałów ufności. Uzyskane wyniki mogą być wsparciem w podejmowaniu decyzji inwestycyjnych i w badaniach nad ryzykiem rynkowym.


2 Rozdział 1 - Analiza kursów zamknięcia i logarytmicznych zwrotów

2.1 Część 1 – Grupa Żywiec ()


Grupa Żywiec to jedna z czołowych polskich spółek zajmujących się produkcją i sprzedażą piwa, która od lat cieszy się popularnością wśród konsumentów w kraju i za granicą. Spółka oferuje szeroki wybór marek piw, takich jak Żywiec, Warka, Tatra, czy Namysłów, dostosowanych do różnych preferencji smakowych – od piw jasnych, przez ciemne, po specjalne i sezonowe edycje. Grupa Żywiec jest częścią międzynarodowego koncernu Heineken, co umożliwia jej dostęp do najnowszych technologii oraz globalnych standardów jakości.

2.1.1 Wykresy

Wykresy kursów zamknięcia oraz logarytmicznych zwrotów, ilustrujące zmiany w czasie.



Rysunek 1: Dzienny kurs zamknięcia w czasie.



Rysunek 2: Dzienny logarytmiczny zwrot w czasie.

2.1.2 Estymacja parametrów

Założmy, że log-zwroty $r_1, r_2, \dots, r_n$ są niezależnymi realizacjami zmiennej losowej X o dystrybucji F , wartości oczekiwanej μ i wariancji σ^2 . Zapiszmy wzory odpowiednich estymatorów oraz wykorzystajmy je do estymacji wartości oczekiwanej, wariancji oraz odchylenia standardowego.

Średnia z próby:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = -0.0001501582$$

Wariancja z próby:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = 8.31753 \times 10^{-5}$$

Odchylenie standardowe z próby:


$$S_n = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2} = 0.00912005$$

2.1.3 Estymacja kwantyli

Korzystając z klasycznego estymatora kwantyli, zaimplementowanego w R, wyestymowano kwantyle rzędu $\alpha = 5\%$, 50% i 95% . Wyniki podano w tabeli.

$\bar{x}_n$	s_n^2	s_n	$q(5\%)$	$q(50\%)$	$q(95\%)$
-0.0001501582	8.31753e-05	0.00912005	-0.01477551	0	0.01222011

Tabela 1: Estymacja wartości średniej, wariancji i kwantyli logarytmicznych zwrotów.




Rysunek 3: Histogram logarytmicznych zwrotów z zaznaczonymi kwantylami.

- Kwantyl 5%: Wskazuje wartość zwrotu, poniżej której znajduje się 5% obserwacji, co może być interpretowane jako poziom ryzyka.
- Kwantyl 50%: Jest to mediana, wskazuje wartość środkową, dzielącą próbę na dwie równe części.
- Kwantyl 95%: Wskazuje wartość zwrotu, powyżej której znajduje się 5% obserwacji, co może być przydatne w analizie skrajnie pozytywnych wyników.

2.1.4 Estymator dystrybuanty

Wzór estymatora dystrybuanty:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \{X_i \leq x\}$$



Rysunek 4: Estymacja dystrybuanty F dla logarytmicznych zwrotów.

2.1.5 Część 2 – Estymacja parametrów rozkładu normalnego i t-Studenta oraz ocena dopasowania

2.1.6 Estymacja parametrów za pomocą MLE

Estymator największej wiarygodności (MLE) dla średniej μ w rozkładzie normalnym to średnia z próby:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i$$

- X_i to i -ta obserwacja w próbie.
- n to liczba obserwacji w próbie.

Estymator największej wiarygodności dla odchylenia standardowego w rozkładzie normalnym to:

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \hat{\mu})^2}$$

- $\hat{\mu}$ to estymator średniej z próby.
- X_i to i -ta obserwacja w próbie.
- n to liczba obserwacji w próbie.

Estymowane parametry rozkładu normalnego:


- Średnia (mean): -0.0002411481
- Odchylenie standardowe (sd): 0.0092015784

Estymowane parametry rozkładu t-Studenta:

- Stopnie swobody (df): 328.0497 Bardzo wysoka wartość df sugeruje, że rozkład t-Studenta zachowuje się podobnie do normalnego.

2.1.7 Wykresy diagnostyczne

Na poniższych wykresach przedstawiono porównanie dopasowania rozkładu normalnego oraz t-Studenta do danych log-zwrotów. Każdy wykres przedstawia kształt rozkładu oraz histogram danych:



Rysunek 5: Wykresy diagnostyczne dla rozkładu normalnego i t-Studenta: PDF oraz histogramy.

- **Empiryczna i teoretyczna gęstość (górny lewy):** Histogram sugeruje symetryczny rozkład danych. Dopasowanie rozkładu normalnego wydaje się lepsze niż t-Studenta, ponieważ krzywa niebieska lepiej pokrywa kształt histogramu. Rozkład t-Studenta jest bardziej płaski (ma cięższe ogony), co może wskazywać, że jest mniej adekwatny dla tych danych.
- **Wykres Q-Q (górny prawy):** Dla rozkładu normalnego dane odchylają się od linii prostej, szczególnie na krańcach, co sugeruje, że rozkład normalny nie idealnie opisuje ogony danych. Dla rozkładu t-Studenta dane również odchylają się od linii prostej, ale odchylenie jest bardziej wyraźne, co wskazuje na gorsze dopasowanie w całym zakresie danych.
- **Empiryczna i teoretyczna dystrybuanta (dolny lewy):** Rozkład normalny (czerwona linia) lepiej dopasowuje się do empirycznej CDF w porównaniu z rozkładem t-Studenta, szczególnie w środkowym zakresie danych. Rozkład t-Studenta pokazuje większe rozbieżności, co oznacza, że jego cięższe ogony nie pasują do danych.
- **Wykres P-P (dolny prawy):** Rozkład normalny (czerwone punkty) lepiej przylega do linii prostej (idealne dopasowanie). Rozkład t-Studenta (zielone punkty) odchyła się bardziej, szczególnie w środkowym zakresie i przy krańcach, co wskazuje na gorsze dopasowanie.

Rozkład normalny lepiej dopasowuje się do danych niż rozkład t-Studenta we wszystkich aspektach: Histogram sugeruje lepsze dopasowanie rozkładu normalnego do kształtu danych. Q-Q plot i CDF pokazują, że rozkład t-Studenta ma problemy z opisaniem środkowego zakresu danych oraz ogonów. P-P plot potwierdza, że rozkład normalny jest bardziej adekwatny.

2.1.8 Testy dobroci dopasowania oraz kryteria informacyjne

Kolmogorov–Smirnov

Statystyka Kolmogorova–Smirnova (KS) jest definiowana jako:

$$D_n = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)|,$$

gdzie:

- $\hat{F}_n(x)$ to empiryczna dystrybuanta,
- $F(x)$ to dystrybuanta teoretyczna.

Cramér–von Mises

Statystyka Craméra–von Misesa jest obliczana jako:

$$CM = n \int_{-\infty}^{\infty} (\hat{F}_n(x) - F(x))^2 dx,$$

gdzie:

- $\hat{F}_n(x)$ to empiryczna dystrybuanta,
- $F(x)$ to dystrybuanta teoretyczna.

Anderson–Darling

Statystyka Andersona–Darlinga jest definiowana jako:

$$AD = n \int_{-\infty}^{\infty} \frac{(\hat{F}_n(x) - F(x))^2}{F(x)(1 - F(x))} dx,$$

gdzie:

- $\hat{F}_n(x)$ to empiryczna dystrybuanta,
- $F(x)$ to dystrybuanta teoretyczna.

AIC (Akaike Information Criterion)

AIC jest definiowane jako:

$$AIC = -2 \sum_{i=1}^n \ln(f_{\hat{\theta}}(X_i)) + 2p,$$

gdzie:

- $f_{\hat{\theta}}(X_i)$ to funkcja gęstości prawdopodobieństwa dla X_i z estymowanymi parametrami $\hat{\theta}$,
- p to liczba parametrów w modelu,
- n to liczba obserwacji.

BIC (Bayesian Information Criterion)

BIC jest obliczane jako:

$$BIC = -2 \sum_{i=1}^n \ln(f_{\hat{\theta}}(X_i)) + p \ln(n),$$

gdzie:

- $f_{\hat{\theta}}(X_i)$ to funkcja gęstości prawdopodobieństwa dla X_i z estymowanymi parametrami $\hat{\theta}$,

- p to liczba parametrów w modelu,
- n to liczba obserwacji.

Testy	Rozkład normalny	Rozkład t-Studenta
Kolmogorov-Smirnov (KS)	0.0587	0.7665
Cramer-von Mises (CM)	0.0288	19.5978
Anderson-Darling (AD)	0.1836	100.3036
AIC	407.168	843.435
BIC	412.378	846.040

Tabela 2: Statystyki dobroci dopasowania i kryteria informacyjne dla rozkładu normalnego i t-Studenta.

- **Statystyki dobroci dopasowania:**

- **KS (Kolmogorov-Smirnov):** Rozkład normalny ma mniejszą wartość, co wskazuje na lepsze dopasowanie.
- **CM (Cramer-von Mises):** Rozkład normalny jest znacznie lepszy ze względu na mniejszą wartość statystyki.
- **AD (Anderson-Darling):** Rozkład normalny ponownie lepiej pasuje do danych.

- **Kryteria informacyjne:**

- **AIC:** Normalny (407) vs t-Studenta (843) $\rightarrow$ normalny wygrywa.
- **BIC:** Normalny (412) vs t-Studenta (846) $\rightarrow$ normalny jest lepszy.

Wniosek: Na podstawie statystyk dobroci dopasowania oraz kryteriów informacyjnych, lepiej dopasowanym modelem do danych jest **rozkład normalny**.

2.1.9 Test hipotezy o równości rozkładów

Dla wybranego rozkładu normalnego przeprowadzono test hipotezy przy pomocy statystyki Kolmogorov-Smirnova (KS) z metodą Monte Carlo. Wyniki testu sugerują, że:

- Statystyka KS: 0.0581
- P-wartość testu Monte Carlo: 0.866

Uzasadnienie wyboru metody Monte Carlo z użyciem statystyki KS: Statystyka KS została wybrana, ponieważ mierzy maksymalną różnicę między dystrybucją empiryczną a teoretyczną, co pozwala na dokładną ocenę dopasowania modelu. Metoda Monte Carlo została zastosowana, ponieważ umożliwia oszacowanie rozkładu tej statystyki dla wybranego rozkładu w sposób numeryczny. Jest to szczególnie istotne, gdy klasyczne podejścia analityczne mogą być trudne do zastosowania przy danych o specyficznych cechach, takich jak niewielka liczebność próby czy asymetria. Dzięki Monte Carlo uzyskano dokładną p-wartość, co pozwala na obiektywne wnioskowanie o zgodności rozkładów.

Wniosek: Otrzymana wysoka p-wartość ($p > 0.05$) wskazuje, że nie ma podstaw do odrzucenia hipotezy o zgodności danych z rozkładem normalnym.

2.1.10 Podstawy teoretyczne

- **Statystyka KS (Kolmogorowa-Smirnowa)**: Mierzy maksymalną różnicę między dystrybucją empiryczną a teoretyczną. Mniejsza wartość oznacza lepsze dopasowanie modelu.
- **Statystyki CM i AD**:
 - **Cramer-von Mises (CM)**: Uwzględnia różnice między dystrybucjami na całym zakresie wartości.
 - **Anderson-Darling (AD)**: Uwzględnia różnice z większą wagą dla wartości skrajnych.
- **Kryteria informacyjne (AIC, BIC)**:
 - **AIC (Akaike Information Criterion)**: Używa logarytmu funkcji wiarygodności z karą za liczbę parametrów.
 - **BIC (Bayesian Information Criterion)**: Podobne do AIC, lecz dodatkowo uwzględnia rozmiar próby.
- **Metoda Monte Carlo**: Pozwala oszacować rozkład statystyki testowej poprzez symulacje, co jest szczególnie przydatne w ocenie hipotezy zerowej.

Podsumowanie: Analiza wskazuje, że dane są lepiej dopasowane do rozkładu normalnego niż t-Studenta, co potwierdzają zarówno statystyki dobroci dopasowania, kryteria informacyjne, jak i test Kolmogorov-Smirnova metodą Monte Carlo.

2.2 Część 1 – Nike (Katarzyna Jaczewska)


Nike, Inc. – amerykańskie przedsiębiorstwo będące jednym z największych na świecie producentów obuwia, odzieży i akcesoriów sportowych.

Założone w 1964 w Washington County jako Blue Ribbon Sports przez Billa Bowermana i Philipa Knighta, który do 2004 był prezesem koncernu. Jej nazwa pochodzi od greckiej bogini Nike.

2.2.1 Wykresy



Rysunek 6: Kurs zamknięcia akcji Nike



Rysunek 7: Log-zwroty akcji Nike

2.2.2 Estymacja parametrów

Założmy, że log-zwroty $r_1, r_2, \dots, r_n$ są niezależnymi realizacjami zmiennej losowej X o dystrybucji F , wartości oczekiwanej μ i wariancji σ^2 . Poniżej znajdują się wzory odpowiednich estymatorów wykorzystane do estymacji wartości oczekiwanej, wariancji oraz odchylenia standardowego.

Wartość oczekiwana (średnia z próby):

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = -0.0008117897$$

Wariancja:

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = 0.0005036283$$

Odchylenie standardowe:


$$S_n = \sqrt{\hat{\sigma}^2} = 0.02244166$$

2.2.3 Estymacja kwantyli

	$\bar{x}_n$	s^2_n	s_n	$q(5\%)$	$q(50\%)$	$q(95\%)$
5%	-0.000811789691949366	0.000503628278287292	0.0224416638930203	-0.034593940554359	-0.000429513731259323	0.0320911471402088

Rysunek 8: Kwantyle

2.2.4 Histogram z wyróżnionymi kwantylami



Rysunek 9: Histogram log-zwrotów

2.2.5 Interpretacja kwantyli

Kwantyl 5% ($q(5\%) = -0.03459394$):

Kwantyl 5% oznacza, że 5% log-zwrotów akcji Nike w badanym okresie było mniejszych niż -0.03459394. Jest to wartość, poniżej której znajduje się najniższe 5% obserwacji. Wyestymowana wartość kwantyla wskazuje na rzadkie, duże, nieoczekiwane straty akcji Nike w analizowanym okresie.

Kwantyl 50% ($q(50\%) = -0.0004295137$) - Mediana:

Mediana log-zwrotów, oznacza, że połowa log-zwrotów była mniejsza niż -0.0004295137. Mediana

wskazuje, że w większości dni log-zwroty akcji Nike w tym okresie były bliskie zeru (bardzo niewielkie wahania), a zatem zmiany cen akcji były niewielkie.

Kwantyl 95% ($q(95\%) = 0.03209115$):

Kwantyl 95% oznacza, że 95% log-zwrotów akcji Nike w badanym okresie było mniejszych niż 0.03209115. Wyestymowana wartość kwantyla wskazuje, że tylko w wyjątkowych sytuacjach akcje wzrastały o więcej niż 3%.


2.2.6 Estymator dystrybuanty

Nieobciążonym estymatorem wartości dystrybuanty F , zmiennej losowej X , w punkcie x jest:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i \leq x)$$

gdzie:

- $\hat{F}_n(x)$ to estymator dystrybuanty empirycznej w punkcie x ,
- $\mathbb{I}(X_i \leq x)$ to funkcja wskaźnikowa, która wynosi 1, gdy $X_i \leq x$, i 0 w przeciwnym przypadku,
- n to liczba obserwacji w próbie.



2.2.7 Część 2 – Estymacja parametrów rozkładu normalnego i t-Studenta oraz ocena dopasowania

2.2.8 Estymacja parametrów za pomocą MLE

Estymowane parametry rozkładu normalnego:


- Średnia (mean): -0.0008117897
- Odchylenie standardowe (sd): 0.02244166

Estymowane parametry rozkładu t-Studenta:

- Stopnie swobody (df): 68.7997 Stosunkowo wysoka wartość df wskazuje, że rozkład t-Studenta jest już bardzo bliski normalnemu, więc różnice między tymi rozkładami będą minimalne.

2.2.9 Wykresy diagnostyczne

Poniższe wykresy przedstawiają porównanie dopasowania rozkładu normalnego oraz t-Studenta dla danych log-zwrotów. Każdy wykres ukazuje kształt rozkładu i histogram danych



2.2.10 Opis wykresów diagnostycznych

Histogram and theoritical densities

Wykres przedstawia histogram danych empirycznych oraz teoretyczne krzywe gęstości dla rozkładów normalnego i t-Studenta. Pokazuje on, w jakim stopniu teoretyczne rozkłady odpowiadają rzeczywistej strukturze danych. W przypadku rozkładu normalnego widać, że rozkład teoretyczny dobrze pasuje do rzeczywistej struktury danych, jednak w przypadku rozkładu t-Studenta zauważalne jest znaczące odchylenie od empirycznych danych. Sugeruje to, że dane bardziej przypominają rozkład normalny, a mniej pasują do rozkładu t-Studenta.

Q-Q plot

Wykres przedstawia porównanie kwantyli empirycznych z teoretycznymi dla obu rozkładów. Na wykresie widać, że dla rozkładu normalnego punkty znajdują się na linii referencyjnej, co sugeruje dobre dopasowanie danych do tego rozkładu. Z kolei dla rozkładu t-Studenta punkty odbiegają od linii referencyjnej, co wskazuje na słabsze dopasowanie i odchylenie od teoretycznego rozkładu.

Empirical and theoretical CDFs

Wykres przedstawia porównanie empirycznej dystrybuanty z dystrybuantami teoretycznymi obu rozkładów. Dystrybuanty dla rozkładu normalnego są dobrze dopasowane. Natomiast nie są dla rozkładu t-Studenta. Wskazuje to na lepsze dopasowanie rozkładu normalnego do badanych danych.

P-P plot

Wykres P-P porównuje empiryczne prawdopodobieństwa z teoretycznymi dla rozkładów normalnego i t-Studenta. Na wykresie punkty dla rozkładu normalnego znajdują się blisko linii referencyjnej, co sugeruje, że dane dobrze pasują do tego rozkładu. W przypadku rozkładu t-Studenta punkty odbiegają od linii referencyjnej, co wskazuje na brak zgodności danych z tym rozkładem. Zatem, rozkład normalny lepiej odpowiada strukturze danych, podczas gdy rozkład t-Studenta wykazuje wyraźne odchylenia.

2.2.11 Wnioski

Rozkład najlepiej opisujący dane: rozkład normalny

Na podstawie powyższych analiz, rozkład normalny najlepiej opisuje dane. Rozkład t-Studenta wykazuje większe odchylenia i nie pasuje tak dobrze do rzeczywistej struktury danych.

2.2.12 Testy dobroci dopasowania oraz kryteria informacyjne

Statystyka Kolmogorowa-Smirmowa (KS)

normalny: 0.06394384

t-Student: 0.4702879

Niższa statystyka KS oznacza lepsze dopasowanie, gdyż mierzy maksymalną różnicę między empiryczną funkcją rozkładu (CDF) danych a CDF dopasowanego rozkładu.

Rozkład normalny ma znacznie mniejszą wartość KS, co sugeruje, że lepiej pasuje do danych niż rozkład t-Studenta.

Statystyka Cramera-von Misesa (CM)

Normalny: 0.69030031

t-Student: 39.3788374

Niższa wartość statystyki CM wskazuje na lepsze dopasowanie.

Rozkład normalny ma znacząco mniejszą wartość CM, zatem jest lepszym dopasowaniem niż rozkład t-Studenta.

Statystyka Andersona-Darlinga (AD)

Normalny: 4.23325325
t-Student: 183.9917409

Mniejsza wartość statystyki AD oznacza lepsze dopasowanie.
Rozkład normalny ma znacznie mniejszą wartość AD, zatem lepiej pasuje do prezentacji danych niż rozkład t-Studenta.

Akaike's Information Criterion (AIC)

Normalny: -2374.899
t-Student: 924.2241

AIC nakłada dodatkową wartość ma modele z większą liczbą parametrów, aby uniknąć nadmiernego dopasowania. Z tego powodu niższa wartość AIC jest preferowana.
Rozkład normalny ma znacznie niższy AIC, co przemawia za tym, że lepiej opisuje dane.

Bayesian Information Criterion (BIC)

Normalny: -2366.469
t-Student: 928.4387

Niższa wartość BIC oznacza lepsze dopasowanie modelu. Im mniejsza wartość BIC, tym model lepiej balansuje dopasowanie do danych i prostotę (liczbę parametrów).
Rozkład normalny ma znacznie niższy BIC, co również wskazuje, że jest lepszym modelem do opisu danych.

Podsumowanie

Na podstawie wszystkich statystyk dopasowania, rozkład normalny jest lepszym modelem do opisanego danych niż rozkład t-Studenta. Przemawiają za tym niższe wartości rozkładu normalnego we wszystkich tych statystykach.

Analiza wskazuje, że dane są lepiej dopasowane do rozkładu normalnego niż t-Studenta, co potwierdzają zarówno statystyki dobroci dopasowania i kryteria informacyjne. Odrzucenia hipotezy w teście Monte Carlo wskazuje, że dane nie są idealnie zgodne z rozkładem normalnym, mimo że statystyki dopasowania sugerują jego przewagę nad rozkładem t-Studenta. W praktyce oznacza to, że należy zachować ostrożność przy korzystaniu z rozkładu normalnego do dalszych analiz, zwłaszcza w przypadku testów, które są bardzo wrażliwe na założenia dotyczące rozkładu danych.

2.2.13 Test metodą Monte Carlo hipotezy o równości rozkładów

Dla wybranego rozkładu normalnego przeprowadzono test hipotezy przy pomocy statystyki Kołmogorowa-Smirowa (KS) metodą Monte Carlo. Wyniki testu:

Statystyka KS: 0.06394384

p-wartość testu Monte Carlo: 0.034

Podsumowanie Statystyka KS oblicza maksymalną różnicę między dystrybucją empiryczną a teoretyczną. Test Kołmogorowa-Smirnova z metodą Monte Carlo pozwala na porównanie rozkładu empirycznego danych z wybranym rozkładem teoretycznym, przy czym metoda Monte Carlo pomaga w oszacowaniu statystyki KS w sposób numeryczny, co daje bardziej wiarygodne wyniki i p-wartości. Otrzymana w teście p-wartość równa 0.034, czyli mniejsza od poziomu istotności 0.05 oznacza, że są podstawy do odrzucenia hipotezy o równości rozkładów z rozkładem normalnym.

3 Rozdział 2 - Analiza łącznego rozkładu log-zwrotów

Przyjmujemy, że log-zwroty dwóch akcji są niezależnymi realizacjami wektora losowego (X, Y) o nieznanym parametrach.

3.0.1 Estymatory parametrów

- **Wektor średnich:**

$$\hat{\mu} = \begin{bmatrix} \hat{\mu}_X \\ \hat{\mu}_Y \end{bmatrix}, \quad \hat{\mu}_X = \frac{1}{n} \sum_{i=1}^n X_i, \quad \hat{\mu}_Y = \frac{1}{n} \sum_{i=1}^n Y_i$$

- **Macierz kowariancji:**

$$\hat{\Sigma} = \begin{bmatrix} \hat{\sigma}_X^2 & \hat{\text{Cov}}(X, Y) \\ \hat{\text{Cov}}(X, Y) & \hat{\sigma}_Y^2 \end{bmatrix}$$

- **Współczynnik korelacji:**

$$\hat{\rho} = \frac{\hat{\text{Cov}}(X, Y)}{\sqrt{\hat{\sigma}_X^2 \cdot \hat{\sigma}_Y^2}}, \quad \hat{\text{Cov}}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \hat{\mu}_X)(Y_i - \hat{\mu}_Y)$$

- **Macierz korelacji:**

$$\hat{P} = \begin{bmatrix} 1 & \hat{\rho} \\ \hat{\rho} & 1 \end{bmatrix}$$

3.0.2 Wyniki obliczeń

- **Wektor średnich:**

$$\hat{\mu} = \begin{bmatrix} -0.00037 \\ -0.00096 \end{bmatrix}$$

Średnie log-zwroty:

Grupa Żywiec:

$$\hat{\mu}_1 = -0.00037$$

Nike:

$$\hat{\mu}_2 = -0.00096$$

Średnie log-zwroty dla obu akcji są ujemne, co sugeruje niewielki spadek wartości w analizowanym okresie.

- **Macierz kowariancji:**

$$\hat{\Sigma} = \begin{bmatrix} 0.00009 & 0.00003 \\ 0.00002 & 0.00068 \end{bmatrix}$$

Wariancje log-zwrotów:

Grupa Żywiec:

$$\text{Var}(X) = 0.00009$$

Nike:

$$\text{Var}(Y) = 0.00068$$

Wartości wariancji log-zwrotów wskazują, że akcje Nike charakteryzują się większą zmiennością log-zwrotów niż Grupa Żywiec. Wyższa wariancja log-zwrotów akcji Nike oznacza,

że zmiany cen tej akcji są bardziej nieregularne i rozproszone wokół średniego log-zwrotu, co wiąże się z ryzykiem. Z tego powodu jest to istotny czynnik w decyzjach inwestycyjnych.

Kowariancja log-zwrotów obydwu akcji:

$$\text{Cov}(X, Y) = 0.00003$$

Ujemna kowariancja wskazuje, że gdy log-zwroty jednej akcji rosną, log-zwroty drugiej mają tendencję do spadku. Wiąże się to z tym, że obie akcje mają tendencję do kompensowania swoich ruchów cenowych, co potencjalnie zwiększa ich atrakcyjność w kontekście dywersyfikacji portfela inwestycyjnego.


- **Macierz korelacji:**

$$\hat{P} = \begin{bmatrix} 1 & -0.10610 \\ -0.10610 & 1 \end{bmatrix}$$

Wartość współczynnika korelacji między log-zwrotami dwóch akcji wynosi -0.10610 , co wskazuje na umiarkowaną ujemną zależność między tymi dwiema akcjami. Oznacza to, że kiedy log-zwrot jednej akcji rośnie, log-zwrot drugiej akcji ma tendencję do spadku, i odwrotnie. Ujemna korelacja między log-zwrotami obydwu akcji sugeruje, że mogą one działać w sposób kompensacyjny w portfelu inwestycyjnym. Kiedy jedna akcja traci na wartości, druga może zyskać, co zmniejsza ryzyko inwestycyjne.

- **Współczynnik korelacji:**

$$\hat{\rho} = -0.10610$$



Rysunek 10: Wykres rozrzutu z histogramami rozkładów brzegowych.

Wykres rozrzutu

Wiele punktów nakłada się na siebie w centralnym obszarze, co wynika z ograniczonej zmienności zwrotów. To z kolei wskazuje na podobną charakterystykę obu spółek.

Histogramy log-zwrotów

Histogramy wskazują, że logarytmiczne zwroty obu spółek są skoncentrowane wokół zera, co sugeruje, że mają rozkłady o małej średniej i niskiej wariancji. Oznacza to stabilność cen akcji w badanym okresie bez wyraźnego trendu wzrostowego lub spadkowego.

3.0.3 Wzór gęstości rozkładu $\hat{f}$ normalnego o wyestymowanych parametrach $N(\hat{\mu}, \hat{\Sigma})$

Gęstość rozkładu normalnego o wyestymowanych parametrach $N(\hat{\mu}, \hat{\Sigma})$ wyraża się wzorem:

$$\hat{f}(x, y) = \frac{1}{2\pi|\hat{\Sigma}|^{1/2}} e^{-\frac{1}{2} \begin{bmatrix} x - \hat{\mu}_x \\ y - \hat{\mu}_y \end{bmatrix}^T \hat{\Sigma}^{-1} \begin{bmatrix} x - \hat{\mu}_x \\ y - \hat{\mu}_y \end{bmatrix}},$$

gdzie:

$$\hat{\mu} = \begin{bmatrix} \mu_x \\ \mu_y \end{bmatrix} \quad \text{to wektor średnich,}$$

$$\hat{\Sigma} = \begin{bmatrix} \sigma_{xx} & \sigma_{xy} \\ \sigma_{yx} & \sigma_{yy} \end{bmatrix} \quad \text{to macierz kowariancji,}$$

$$|\Sigma| \quad \text{to wyznacznik macierzy}$$

3.0.4 Wzory gęstości brzegowych

Gęstości brzegowe dla X i Y są dane wzorami:

$$\hat{f}_X(x) = \frac{1}{\sqrt{2\pi\hat{\sigma}_X^2}} \exp\left(-\frac{(x - \hat{\mu}_X)^2}{2\hat{\sigma}_X^2}\right), \quad \hat{\sigma}_X^2 = 0.00009$$

$$\hat{f}_Y(y) = \frac{1}{\sqrt{2\pi\hat{\sigma}_Y^2}} \exp\left(-\frac{(y - \hat{\mu}_Y)^2}{2\hat{\sigma}_Y^2}\right), \quad \hat{\sigma}_Y^2 = 0.00068$$

Wariancje:

Grupa Żywiec:

$$\hat{\sigma}_X^2 = 0.00009$$

Bardzo niska wartość wariancji wskazuje, że cena akcji Grupy Żywiec jest stosunkowo stabilna i oscyluje blisko swojej średniej.


Spółka o małej zmienności cen akcji jest uznawana za stabilną i mniej ryzykowną inwestycję. Grupa Żywiec działa w branży stabilnej, takiej jak dobra konsumpcyjne, co może dodatkowo przyczyniać się do jej niskiej zmienności. Tego rodzaju spółki często cechują się większą kapitalizacją i są preferowane przez inwestorów poszukujących przewidywalnych zwrotów w dłuższym horyzoncie czasowym.

Nike:


$$\hat{\sigma}_Y^2 = 0.00068$$

Wyższa wariancja oznacza, że cena akcji spółki Nike ma większe rozproszenie wokół średniej. Oznacza to, że ceny tej spółki częściej zmieniają się w większym zakresie. Wynika to z tego, że spółka Nike działa w branży odzieżowo-sportowej, która jest bardziej podatna na zmiany sezonowe, trendy konsumenckie oraz wahania rynkowe. Tego typu branże cechują się większymi zmianami wartości akcji w odpowiedzi na wiadomości rynkowe, co zwiększa wariancję i potencjał do szybkich zysków jak i strat. Spółka Nike może zainteresować inwestorów skłonnych do ryzyka, którzy liczą na większe potencjalne zyski z krótkoterminowych wahań cen.

3.0.5 Wyniki graficzne




Rysunek 11: Wykres gęstości łącznej $\hat{f}$ dla log-zwrotów dwóch akcji.



Rysunek 12: Wykresy gęstości brzegowych: $\hat{f}$ dla log-zwrotów dwóch akcji.

3.0.6 Próba liczności danych z rozkładu



Rysunek 13: Wykresy próby liczności danych z rozkładu: $\hat{f}$ dla log-zwrotów dwóch akcji.

3.1 Porównanie wykresów rozrzutu i ocena zgodności z rozkładem normalnym

Na podstawie wykresu rozrzutu wygenerowanej próby i wykresu rozrzutu danych można wyciągnąć następujące wnioski:

3.1.1 Porównanie wykresów rozrzutu

1. Wykres z wygenerowaną próbką:

- Wygenerowany rozkład przypomina rozkład dwuwymiarowy normalny.
- Izolinie są elipsami skoncentrowanymi wokół środka, co jest typowe dla rozkładu normalnego w dwóch wymiarach.

2. Wykres rozrzutu danych:

- Wykres rozrzutu rzeczywistych danych wskazuje skoncentrowanie punktów w centralnej części zakresu. Wzorzec eliptyczny jest wyraźny, ponieważ gęstość w centralnej części jest wysoka. Elipsa ma bardziej wydłużony kształt w kierunku pionowym (na osi y), co sugeruje, że w danych rzeczywistych istnieje większa zmienność w tej osi w porównaniu do osi poziomej (x).
- Wykres rozrzutu symulowanych danych wskazuje na stosunkowo równomiernie rozproszone punkty w całym zakresie. Wzorzec eliptyczny jest obecny, ale punkty są równomiernie rozproszone. Elipsa w danych symulowanych wydaje się bardziej symetryczna, z podobnym rozkładem zmienności w obu osiach, co wskazuje na brak istotnych zależności w danych.

3.1.2 Ocena wstępna zgodności

- Rzeczywiste dane (na wykresie rozrzutu) wydają się zgodne z rozkładem normalnym w centrum (wartości w pobliżu środka), ale występują odchylenia w ogonach.
- Wykres gradientowy (dla rozkładu wygenerowanego) wskazuje na dobrze dopasowany model do rozkładu normalnego, co może być wynikiem estymacji parametrów.

3.1.3 Wnioski

- Na podstawie obu wykresów można stwierdzić, że dane rzeczywiste nie są idealnie zgodne z rozkładem normalnym, co ujawniają odstępstwa w wartościach ekstremalnych. Wyestymowane parametry modelu normalnego dobrze przybliżają dane w środkowym zakresie wartości, jednak obecność wartości skrajnych, wskazują na potrzebę zastosowania bardziej złożonego modelu rozkładu. Przykładem może być rozkład t-Studenta, który ma większe prawdopodobieństwo występowania wartości ekstremalnych w porównaniu do rozkładu normalnego.

4 Rozdział 3 - Regresja liniowa dla log-zwrotów

W analizie regresji liniowej dla logarytmicznych zwrotów dwóch spółek zastosowano estymację parametrów regresji oraz wyznaczono przedziały ufności dla wartości oczekiwanej log-zwrotów. Testy normalności rozkładów wskazały brak podstaw do odrzucenia hipotezy o normalności, co umożliwiło wykorzystanie analitycznych wzorów do obliczeń.

4.1 Przedziały ufności dla wartości oczekiwanej log-zwrotów

Dla log-zwrotów spółek zastosowano wzór na przedział ufności:

$$CI = \left[\bar{X} - t_{\alpha/2, n-1} \cdot \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2, n-1} \cdot \frac{S}{\sqrt{n}} \right], \quad (1)$$

gdzie:

- $\bar{X}$ - średnia log-zwrotów,
- S - odchylenie standardowe log-zwrotów,
- n - liczba obserwacji,
- $t_{\alpha/2, n-1}$ - kwantyl rozkładu t-Studenta dla poziomu ufności $1 - \alpha$ i $n - 1$ stopni swobody.

Obliczone przedziały ufności przedstawiono w Tabeli 3.

Spółka	Przedział ufności (95%)	Średnia ($\bar{X}$)
Spółka 1	$[-0.001524524, 0.0007848567]$	$[-0.000369]$
Spółka 2	$[-0.00420535, 0.002292224]$	$[-0.000956]$

Tabela 3: Przedziały ufności dla wartości oczekiwanej log-zwrotów.

4.1.1 Wnioski

Analiza wykazała, że:

- Log-zwroty obu spółek charakteryzują się różnymi wartościami oczekiwanymi, co może sugerować różnice w dynamice zmian cen akcji.
- Współczynnik korelacji pomiędzy log-zwrotami spółek był ujemny i nie miał wyrażnej wagi, co wskazuje na słabą zależność wzrostu log-zwrotu jednej spółki przy spadku drugiej spółki.
- Wykorzystanie analitycznych przedziałów ufności jest zasadne przy założeniu normalności rozkładu log-zwrotów.

4.2 Teoria regresji liniowej

W analizie regresji liniowej dla logarytmicznych zwrotów dwóch spółek zastosowano estymację parametrów regresji oraz wyznaczono przedziały ufności dla wartości oczekiwanej log-zwrotów (*każdej spółki osobno*). Wstępne testy normalności log-zwrotów R_1 i R_2 obu spółek (jako pojedynczych szeregów czasowych) nie dały podstaw do odrzucenia hipotezy o normalności, co umożliwiło wykorzystanie **analitycznych wzorów do obliczania przedziałów ufności dla ich średnich** (Tabela 3).

Jednakże – co pokażemy później – w samym modelu regresji (gdzie badamy reszty ε) test normalności wskazuje odchylenie reszt od rozkładu normalnego.

4.3 Przedziały ufności dla wartości oczekiwanej log-zwrotów

Dla log-zwrotów spółek zastosowano wzór na przedział ufności dla średniej:

$$CI = \left[\bar{X} - t_{\alpha/2, n-1} \cdot \frac{S}{\sqrt{n}}, \quad \bar{X} + t_{\alpha/2, n-1} \cdot \frac{S}{\sqrt{n}} \right], \quad (2)$$

gdzie:

- $\bar{X}$ – średnia log-zwrotów (danej spółki),
- S – odchylenie standardowe log-zwrotów (z próby),
- n – liczba obserwacji,
- $t_{\alpha/2, n-1}$ – kwantyl rozkładu t-Studenta dla poziomu ufności $1 - \alpha$ i $n - 1$ stopni swobody.

Obliczone przedziały ufności przedstawiono w Tabeli 3.

Spółka	Przedział ufności (95%)	Średnia ($\bar{X}$)
Spółka 1	$[-0.001524524, 0.0007848567]$	-0.000369
Spółka 2	$[-0.00420535, 0.002292224]$	-0.000956

Tabela 4: Przedziały ufności dla wartości oczekiwanej log-zwrotów.

4.3.1 Wnioski

Analiza wykazała, że:

- Log-zwroty obu spółek charakteryzują się różnymi wartościami oczekiwanymi (co widać po różnych środkach przedziałów ufności), co może sugerować różnice w dynamice zmian cen akcji.

- Współczynnik korelacji pomiędzy log-zwrotami spółek jest ujemny i niewielki, wskazując na słabą współzależność.
- W przypadku *pojedynczych* szeregów log-zwrotów nie stwierdzono wyraźnego odstępstwa od normalności – stąd użycie analitycznych przedziałów ufności dla $\bar{X}$.

4.4 Teoria regresji liniowej

W kolejnej części przeanalizowano **współzależność** logarytmicznych zwrotów dwóch spółek (R_1 i R_2) za pomocą modelu klasycznej regresji liniowej. Zbadano reszty modelu, istotność współczynników oraz wykonano predykcję wraz z przedziałami ufności.

Regresja liniowa jest metodą statystyczną służącą do modelowania relacji pomiędzy zmienną zależną Y a jedną lub większą liczbą zmiennych niezależnych X . W przypadku **prostego** modelu liniowego równanie regresji przyjmuje postać:

$$R_2 = b_0 + b_1 \cdot R_1 + \varepsilon,$$

gdzie:

- b_0 – wyraz wolny, określający punkt przecięcia prostej regresji z osią Y ,
- b_1 – współczynnik kierunkowy, opisujący zmianę Y przy jednostkowej zmianie X ,
- ε – składnik losowy (reszty), który w *modelu klasycznym* zakładamy jako niezależny i zgodny z rozkładem normalnym $\varepsilon \sim N(0, \sigma^2)$.

Współczynnik determinacji R^2 opisuje, jaka część *wariancji* zmiennej zależnej Y jest wyjaśniana przez zmienną niezależną X . Wartości R^2 mieszczą się w przedziale $[0, 1]$. Im wyższe R^2 , tym lepsze dopasowanie modelu do danych.

4.4.1 Dopasowanie modelu

Dopasowano model regresji liniowej do danych log-zwrotów spółek. Wyniki estymacji współczynników przedstawiono w Tabeli 4.

Współczynnik	Estymata	Błąd standardowy	p-wartość
b_0	-0.00108	0.00165	0.5171
b_1	-0.29853	0.17730	0.0935

Tabela 5: Estymaty współczynników modelu regresji.

Współczynnik determinacji wynosi

$$R^2 = 0.01126,$$

co oznacza, że model wyjaśnia około 1.13% zmienności zmiennej R_2 . Jest to wartość bardzo niska, wskazująca na słabą (liniową) współzależność między R_1 a R_2 .


4.4.2 Analiza reszt

Kolejnym krokiem jest analiza rozkładu reszt ε z tego modelu:

- Histogram reszt (rysunek 14) sugeruje ogólną symetrię wokół zera, kształtem przypominając rozkład normalny.
- Na wykresie QQ-plot (rysunek 14) punkty w środku rozkładu układają się blisko linii prostej, jednak na krańcach widoczne są odchylenia.

- **Test Shapiro-Wilka** ($p = 0.000009$) oraz **test Andersona-Darlinga** ($p = 0.012902$) dają wartości $p < 0.05$. Oznacza to, że *odrzucaamy* hipotezę o normalności reszt, czyli formalnie ε *nie* jest zgodne z $N(0, \sigma^2)$.

Mimo że wykresy *wizualnie* mogą przypominać kształt normalny, testy statystyczne wykazały istotne odstępstwa na poziomie 5%.



Rysunek 14: Histogram reszt, Q-Q-plot i rozkład bootstrapowych przewidywań.

4.4.3 Predykcja

Dla średniego poziomu log-zwrotów $R_1 = -0.00037$ przewidywana wartość R_2 (wg wyestymowanego modelu) wynosi:

$$\hat{R}_2 = -0.00096.$$


Przedziały ufności Choć reszty nie są idealnie normalne, zaprezentowano *analityczny* przedział ufności (bazujący na założeniu normalności) oraz *przedział ufności bootstrapowy* (który nie wymaga ścisłej normalności) – oba na poziomie 95%:

- Analityczny przedział ufności: $[-0.00419, 0.00228]$.
- Bootstrapowy przedział ufności ($B = 1000$): $[-0.00388, 0.00233]$.


Rysunek 15 przedstawia rozkład bootstrapowych przewidywań oraz reszty w funkcji przewidywanych wartości.

4.4.4 Wizualizacja dopasowania

Wykres rozrzutu log-zwrotów obu spółek z naniesioną linią regresji przedstawiono na rysunku 16. Czerwona linia reprezentuje dopasowany model regresji, a niebieskie punkty to dane empiryczne.



Rysunek 15: Rozkład bootstrapowych przewidywań oraz reszty w funkcji przewidywań.



Rysunek 16: Wykres rozrzutu log-zwrotów z linią regresji.

4.5 Analiza modelu uproszczonego

Ponieważ zarówno wyraz wolny (b_0), jak i współczynnik kierunkowy (b_1) w **pełnym modelu** okazały się na poziomie 5% nieistotne statystycznie ($p > 0.05$), **rozważono model bez wyrazu**

wolnego:

$$R_2 = b_1 \cdot R_1.$$

Tego typu model może być czasem rozważany, jeśli istnieje uzasadnienie (np. wymuszenie przejścia przez $(0, 0)$).

4.5.1 Dopasowanie modelu uproszczonego

Oszacowano zatem *jeden* parametr b_1 , przyjmując $b_0 = 0$. Wyniki estymacji przedstawia Tabela 5.

Współczynnik	Estymata	Błąd standardowy	p-wartość
b_1	-0.2985	0.1773	0.0935

Tabela 6: Estymaty współczynników modelu uproszczonego (bez wyrazu wolnego).

Choć p-wartość ≈ 0.0935 jest nieco mniejsza niż w modelu pełnym, wciąż przy standardowym $\alpha = 0.05$ nie uznaje się go za istotny. Z punktu widzenia $\alpha = 0.10$ można by jednak rozważyć marginalną istotność.

4.5.2 Predykcja w modelu uproszczonym

Dla średniego log-zwrotu $R_1 = -0.00037$ przewidywana wartość R_2 (w tym modelu *bez interceptu*) to:

$$\hat{R}_2^{(\text{simplif.})} = b_1 \cdot (-0.00037) \approx 0.00096.$$

4.5.3 Przedziały ufności

Wyznaczono przedziały ufności dla $\hat{R}_2$ w modelu uproszczonym, zarówno klasycznie (analitycznie), jak i metodą bootstrap (B=1000). Przykładowe wartości to:

- Analityczny: $CI_{\text{analityczny}} = [-0.1525, 0.0691]$.
- Bootstrapowy: $CI_{\text{bootstrap}} = [-0.1245, 0.0498]$.

Zbiorcze wyniki przedstawia Tabela 6.

Metoda	Dolna granica	Górna granica
Analityczny	-0.1525	0.0691
Bootstrapowy	-0.1245	0.0498


Tabela 7: Przedziały ufności dla przewidywanej wartości R_2 (model bez wyrazu wolnego).

Wizualizacja bootstrapu Rysunek 17 prezentuje histogram bootstrapowych przewidywań (zaznaczono średnią przewidywań).

Wnioski z analizy modelu uproszczonego:

- Współczynnik determinacji wciąż jest bardzo niski ($R^2 \approx 0.01126$), co sygnalizuje, że nawet w modelu uproszczonym *nie* wyjaśniamy istotnej części zmienności R_2 .
- Ponieważ współczynnik b_1 jest nieistotny (dla $\alpha = 0.05$), a b_0 również, w praktyce mogłoby się okazać, że żaden komponent *liniowy* nie jest użyteczny w przewidywaniu R_2 na podstawie R_1 .

Podsumowanie:



Rysunek 17: Rozkład bootstrapowych przewidywań (model uproszczony).

- Zarówno w modelu pełnym ($b_0 + b_1 R_1$), jak i uproszczonym (bez wyrazu wolnego) współczynniki nie są statystycznie istotne ($p > 0.05$). Oznacza to brak dowodów na silną liniową zależność między log-zwrotami spółek.
- Przedziały ufności (zarówno analityczne, jak i bootstrapowe) dla przewidywanych wartości są dość szerokie, co dodatkowo wskazuje na niepewność takich prognoz.
- Niskie R^2 (≈ 0.0113) potwierdza, że uwzględnienie wyłącznie R_1 *nie* pozwala skutecznie wyjaśniać zmienności R_2 . W praktyce warto poszukać dodatkowych zmiennych objaśniających lub rozważyć inne modele (nieliniowe, wielorównaniowe itp.).
- Testy normalności dla *reszt* w modelu regresyjnym wykazały odchylenie od normalności ($p < 0.05$), co dodatkowo uzasadnia sięganie po metody nieparametryczne, takie jak bootstrap.

Wnioski końcowe: Przeprowadzona analiza logarytmicznych zwrotów obu spółek (najpierw osobno – w celu wyznaczenia 95% przedziałów ufności dla $\bar{R}_1$ i $\bar{R}_2$, a następnie we wspólnym modelu regresji) pokazała, że:

- Log-zwroty każdej spółki można *oszacować* i obudować przedziałami ufności na podstawie wzorów zakładających normalność (gdyż dla *samych log-zwrotów* nie odrzuciliśmy normalności).
- Natomiast związek pomiędzy R_1 a R_2 (badany przez regresję) okazuje się słaby, a reszty nie są idealnie normalne. W efekcie żadna postać prostej regresji (z bądź bez wyrazu wolnego) nie daje istotnych wyników, a R^2 jest bardzo niskie.
- Przy tak niskim dopasowaniu i braku normalności reszt *przedziały ufności* – zwłaszcza obliczone klasyczną metodą – należy traktować ostrożnie. Zastosowanie bootstrapu daje alternatywny (zwykle zbliżony) sposób oceny niepewności.

Wyniki sugerują, że obie spółki mogą podlegać odmiennym czynnikom rynkowym i *nie* wykazują wyraźnej korelacji *logarytmicznych* stóp zwrotu. W kontekście dalszych analiz (np. budowania portfeli inwestycyjnych) warto byłoby uwzględnić inne czynniki bądź rozpatrywać modele wielowymiarowe.

5 Podsumowanie

Przeprowadzona analiza wykazała, że w badanym okresie dane logarytmicznych zwrotów spółek cechowały się niewielkimi wartościami średnimi (często ujemnymi), co sugeruje, iż obserwowane zmiany cen nie były silnie pro-wzrostowe.

Wyniki testów dobroci dopasowania jednoznacznie wskazywały na przewagę rozkładu normalnego nad rozkładem t-Studenta w wyjaśnianiu empirycznych log-zwrotów, co potwierdziły zarówno statystyki (KS, CM, AD), jak i kryteria informacyjne (AIC, BIC). Wysoki poziom dopasowania rozkładu normalnego w badanym przedziale czasowym wskazuje, że rozkład ten dobrze opisuje dane szczególnie w środkowym zakresie wartości, choć zawsze warto pamiętać o możliwości występowania „grubszych ogonów” w innych warunkach rynkowych.

Dalsza część analizy sugeruje, że korelacja pomiędzy log-zwrotami wybranych akcji była ujemna, co może mieć znaczenie z punktu widzenia dywersyfikacji portfela. Równocześnie wyniki regresji liniowej (wysoka wartość p-wartości dla współczynników, niskie R^2) sygnalizują, że prosta zależność liniowa nie jest wystarczająca do opisu współzależności pomiędzy spółkami, a potencjalne interakcje wymagają bardziej rozbudowanych modeli.

Prezentowane przedziały ufności wskazują na to, że w niniejszej analizie metody parametryczne (z założeniem normalności) można stosować z powodzeniem. Należy jednak uwzględnić, że w innych horyzontach czasowych bądź dla innych aktywów stosowne mogą okazać się bardziej elastyczne rozkłady (np. t-Studenta, rozkłady z grubszymi ogonami), zwłaszcza w momentach podwyższonej zmienności rynkowej.

Podsumowując, przedstawiona analiza stanowi wartościowy punkt wyjścia do dalszych badań nad zachowaniem wybranych spółek w odmiennych reżimach rynkowych oraz do rozbudowanych analiz portfelowych. Wyniki wskazują na stabilne dopasowanie rozkładu normalnego dla analizowanych okresów, co potwierdzają liczne testy. W przyszłości warto jednak zwrócić uwagę na ewentualne zmiany w strukturze rynku i czynnikach makroekonomicznych, które mogą wpływać na kształt rozkładu logarytmicznych zwrotów i jego przydatność w modelowaniu ryzyka.